



Recuperación de Información Multimedia

Análisis de Componentes Principales

CC5213 – Recuperación de Información Multimedia

Departamento de Ciencias de la Computación

Universidad de Chile

Juan Manuel Barrios – <https://juan.cl/mir/> – 2019



Reducción de la dimensión

- Transformar vectores de d dimensiones en vectores de d' dimensiones ($d' \ll d$) perdiendo la menor cantidad de información posible
- Ventajas
 - Eliminar ruido y/o dimensiones redundantes
 - Mejorar eficiencia de la búsqueda: Menos dimensiones → Distancias más rápidas de calcular, Menos requerimiento de memoria
- Método a estudiar: Análisis de Componentes Principales (PCA)



Conceptos

■ Dados $x=\{x_1, \dots, x_n\}$ e $y=\{y_1, \dots, y_n\}$

□ Media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

□ Varianza:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

□ Covarianza:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

■ >0 : valores aumentan o disminuyen juntos

■ <0 : cuando un valor aumenta el otro disminuye



Matriz de Covarianza

- Para espacios d -dimensionales:

$$C^{d \times d} = (c_{ij} | c_{ij} = \text{cov}(Dim_i, Dim_j))$$

- Notar que es una matriz simétrica
- Ejemplo: en 3 dimensiones

$$C = \begin{pmatrix} \text{cov}(x, x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(y, x) & \text{cov}(y, y) & \text{cov}(y, z) \\ \text{cov}(z, x) & \text{cov}(z, y) & \text{cov}(z, z) \end{pmatrix}$$



Valores y Vectores Propios

- Para una matriz de $n \times n$ (transformación lineal) se buscan los vectores v tales que:

$$Av = \lambda v$$

donde λ es un real, es decir, los vectores que no son modificados por la transformación (salvo escala)

- Resolver el polinomio característico igual a 0:

$$p(\lambda) = \det(A - \lambda I) = 0$$

- Para cada solución λ_i buscar el vector asociado (considerar multiplicidades):

$$(A - \lambda_i I)v = 0$$



Valores y Vectores Propios

- Si A es simétrica con valores reales:
 - Sus n valores propios son reales (multiplicidad ≥ 1)
 - Sus n vectores propios son ortogonales entre si
 - Sus n vectores propios son unitarios (norma 1)
 - A puede ser descompuesta en:
$$A = Q D Q^T$$
 - Q es matriz ortogonal cuyas columnas son los vectores propios de A
 - D es matriz diagonal cuyos valores son los valores propios de A



Análisis de Componentes Principales

- Principal Component Analysis (PCA)
 - Aplicar una transformación lineal a los datos (multiplicar cada vector por una matriz)
 - Crea un nuevo conjunto de datos sin covarianzas
 - Descartar dimensiones de baja varianza (es decir, con “poca información”)
 - También conocida como la transformación Karhunen-Loève (KLT)



Algoritmo de PCA

- Entrada: vectores en \mathbb{R}^d
- Centrar los datos (restar la media en cada dimensión)

$$\hat{x} = x - \bar{x}$$

- Calcular la matriz de covarianzas

$$\hat{C} = \begin{pmatrix} cov(\hat{x}, \hat{x}) & cov(\hat{x}, \hat{y}) & cov(\hat{x}, \hat{z}) \\ cov(\hat{y}, \hat{x}) & cov(\hat{y}, \hat{y}) & cov(\hat{y}, \hat{z}) \\ cov(\hat{z}, \hat{x}) & cov(\hat{z}, \hat{y}) & cov(\hat{z}, \hat{z}) \end{pmatrix}$$



Algoritmo de PCA

- De la matriz de covarianzas calcular valores propios $\{\lambda_1, \dots, \lambda_d\}$ con sus correspondientes vectores propios $\{w_1, \dots, w_d\}$
- Reordenar valores propios de mayor a menor:
 - 1er componente principal es el vector propio asociado al mayor valor propio
 - 2º componente principal es el vector propio asociado al segundo mayor valor propio
 - El d -ésimo (y último) componente principal es el vector propio asociado al menor valor propio



Algoritmo de PCA

- Definir matriz de transformación:

$$W = (w_1 ; w_2 ; \dots ; w_d)$$

- Para disminuir la dimensión basta seleccionar las primeras k columnas ($k \leq d$)
- Criterio para escoger k :
 - La suma de todos los valores propios representa la “cantidad de varianza” en el conjunto
 - Seleccionar los k valores propios que sumen una cierta fracción del total, es decir, dado un parámetro p cercano a 1 escoger k que obtenga:

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i} \sim p$$



Algoritmo de PCA


- Transformación de los datos:

$$y = W^T \cdot \hat{x}$$

- Reconstrucción de los datos:

$$x = ((W^T)^{-1} \cdot y) + \hat{x} = ((W^T)^T \cdot y) + \hat{x} = (W \cdot y) + \hat{x}$$

Ejemplo



- Centrar los datos
(restar el promedio)
 - Opcional: escalar por el
inverso de la
desviación
(estandarización)
- Calcular la matriz de
covarianzas:

$$\hat{\Sigma} = \begin{pmatrix} 0.61656 & 0.61544 \\ 0.61544 & 0.71656 \end{pmatrix}$$



Ejemplo

- Calcular valores y vectores propios

- Valores propios:

$$\lambda_1 = 0.049083 \quad \lambda_2 = 1.284$$

- Vectores propios:

$$\begin{pmatrix} -0.73518 & -0.67787 \\ 0.67787 & -0.73518 \end{pmatrix}$$

\uparrow
 w_1

\uparrow
 w_2

Ejemplo

- Reordenar de mayor a menor

- Valores propios (reordenados):

$$\lambda_1 = 1.284 \quad \lambda_2 = 0.049083$$

- Vectores propios (reordenados):

$$\begin{pmatrix} -0.67787 & -0.73518 \\ -0.73518 & 0.67787 \end{pmatrix}$$

\uparrow
 w_1

\uparrow
 w_2



Ejemplo

- Transformación que descarta las covarianzas (mantiene el número de dimensiones):

$$W = (w_1; w_2) = \begin{pmatrix} -0.67787 & -0.73518 \\ -0.73518 & 0.67787 \end{pmatrix}$$



- Transformación que selecciona las k componentes principales:

$$W = (w_1) = \begin{pmatrix} -0.67787 \\ -0.73518 \end{pmatrix}$$

- Transformar los datos:



$$y = W^T \cdot \hat{x}$$

Transformación





Transformación que mantiene el número de dimensiones, sólo elimina las covarianzas de los datos

Reducción



Mantiene un $\lambda_1/(\lambda_1+\lambda_2)=96.3\%$ del “total de la varianza” del conjunto

Reconstrucción



Con la transformación inversa y sumando la promedio se pueden devolver los datos al espacio original




USOS

Normalización de Pose

- PCA se puede usar para obtener ejes de rotación de un objeto
 - Permite normalizar la postura de un objeto
 - No funciona bien para objetos simétricos





PCA sobre imágenes

- Usar la imagen gris como vector de $W \times H$ dimensiones
- Usando PCA se reduce la dimensión, por ej., de varios miles a 256
- Se calcula distancia Euclidiana en el espacio de dimensión reducida

Eigenfaces

- Sistema reconocedor de rostros.
- Cara promedio y los primeros 5 vectores propios





PCA sobre imágenes

■ Eigenobjects:

- Si tenemos muchas imágenes parecidas, cada imagen puede ser vista como la imagen promedio más la suma ponderada de M vectores propios, llamados los “eigenobjects”
- Cada imagen de la colección se representa por un conjunto de M escalares



Variantes de PCA

- PCA es un método lineal no supervisado
 - Transformaciones no lineales: Kernel PCA
 - Supervisado: Fisher's LDA
- Otros métodos: CCA, MDS, ICA, CFA, SOM, ISOMAP, LLE, NNCA.
- Específico a descriptores de texto: LSA

Bibliografía

- **Multimedia Retrieval.** Blanken, de Vries, Blok, Feng. 2007.
 - pág 83 (PCA)
 - pág 165 (eigenobjects)

