



# Recuperación de Información Multimedia

## Análisis de Componentes Principales

**CC5213 – Recuperación de Información Multimedia**

Departamento de Ciencias de la Computación

Universidad de Chile

Juan Manuel Barrios – <https://juan.cl/mir/> – 2020



# Reducción de la dimensión

- Transformar vectores de  $d$  dimensiones en vectores de  $d'$  dimensiones ( $d' < d$ ) descartando la menor cantidad de información posible
- Ventajas
  - Eliminar ruido y/o dimensiones redundantes
  - Mejorar eficiencia de la búsqueda: Menos dimensiones → Distancias más rápidas de calcular, Menos requerimiento de memoria
- Método a estudiar: Análisis de Componentes Principales (PCA)



# Conceptos

- Dados  $x=\{x_1, \dots, x_n\}$  e  $y=\{y_1, \dots, y_n\}$

- Media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Varianza:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Covarianza:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- $>0$ : valores aumentan o disminuyen juntos
    - $<0$ : cuando un valor aumenta el otro disminuye



# Matriz de Covarianza

- Para espacios  $d$ -dimensionales:

$$C^{d \times d} = (c_{ij} | c_{ij} = \text{cov}(Dim_i, Dim_j))$$

- Notar que es una matriz simétrica
- Ejemplo: en 3 dimensiones

$$C = \begin{pmatrix} \text{cov}(x, x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(y, x) & \text{cov}(y, y) & \text{cov}(y, z) \\ \text{cov}(z, x) & \text{cov}(z, y) & \text{cov}(z, z) \end{pmatrix}$$



# Valores y Vectores Propios

- Para una matriz de  $n \times n$  (transformación lineal) se buscan los vectores  $v$  tales que:

$$Av = \lambda v$$

donde  $\lambda$  es un real, es decir, los vectores que no son modificados por la transformación (salvo escala)

- Resolver el polinomio característico igual a 0:

$$p(\lambda) = \det(A - \lambda I) = 0$$

- Para cada solución  $\lambda_i$  buscar el vector asociado (considerar multiplicidades):

$$(A - \lambda_i I)v = 0$$



# Valores y Vectores Propios

- Si  $A$  es simétrica con valores reales:
  - Sus  $n$  valores propios son reales (multiplicidad  $\geq 1$ )
  - Sus  $n$  vectores propios son ortogonales entre si
  - Sus  $n$  vectores propios son unitarios (norma 1)
  - $A$  puede ser descompuesta en:
$$A = Q D Q^T$$
    - $Q$  es matriz ortogonal cuyas columnas son los vectores propios de  $A$
    - $D$  es matriz diagonal cuyos valores son los valores propios de  $A$



# Análisis de Componentes Principales

- Principal Component Analysis (PCA)
  - Aplicar una transformación lineal a los datos (multiplicar cada vector por una matriz)
  - Crea un nuevo conjunto de datos sin covarianzas
  - Descartar dimensiones de baja varianza (es decir, con “poca información”)
  - También conocida como la transformación Karhunen-Loève (KLT)



# Algoritmo de PCA

- Entrada: vectores en  $\mathbb{R}^d$
- Centrar los datos (restar la media en cada dimensión)

$$\hat{x} = x - \bar{x}$$

- Calcular la matriz de covarianzas

$$\hat{C} = \begin{pmatrix} cov(\hat{x}, \hat{x}) & cov(\hat{x}, \hat{y}) & cov(\hat{x}, \hat{z}) \\ cov(\hat{y}, \hat{x}) & cov(\hat{y}, \hat{y}) & cov(\hat{y}, \hat{z}) \\ cov(\hat{z}, \hat{x}) & cov(\hat{z}, \hat{y}) & cov(\hat{z}, \hat{z}) \end{pmatrix}$$





# Algoritmo de PCA

- De la matriz de covarianzas calcular valores propios  $\{\lambda_1, \dots, \lambda_d\}$  con sus correspondientes vectores propios  $\{w_1, \dots, w_d\}$
- Reordenar valores propios de mayor a menor:
  - 1er componente principal es el vector propio asociado al mayor valor propio
  - 2º componente principal es el vector propio asociado al segundo mayor valor propio
  - El  $d$ -ésimo (y último) componente principal es el vector propio asociado al menor valor propio



# Algoritmo de PCA

- Definir matriz de transformación:

$$W = ( w_1 ; w_2 ; \dots ; w_d )$$

- Para disminuir la dimensión basta seleccionar las primeras  $k$  columnas ( $k \leq d$ )
- Criterio para escoger  $k$ :
  - La suma de todos los valores propios representa la “cantidad de varianza” en el conjunto
  - Seleccionar los  $k$  valores propios que sumen una cierta fracción del total, es decir, dado un parámetro  $p$  cercano a 1 escoger  $k$  que obtenga:

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i} \sim p$$



# Algoritmo de PCA


- Transformación de los datos:

$$y = W^T \cdot \hat{x}$$

- Reconstrucción de los datos:

$$x = ((W^T)^{-1} \cdot y) + \hat{x} = ((W^T)^T \cdot y) + \hat{x} = (W \cdot y) + \hat{x}$$

# Ejemplo



- Centrar los datos  
(restar el promedio)
  - Opcional: escalar por el  
inverso de la  
desviación  
(estandarización)
- Calcular la matriz de  
covarianzas:

$$\hat{\Sigma} = \begin{pmatrix} 0.61656 & 0.61544 \\ 0.61544 & 0.71656 \end{pmatrix}$$



# Ejemplo

- Calcular valores y vectores propios

- Valores propios:

$$\lambda_1 = 0.049083 \quad \lambda_2 = 1.284$$

- Vectores propios:

$$\begin{pmatrix} -0.73518 & -0.67787 \\ 0.67787 & -0.73518 \end{pmatrix}$$

$\uparrow$   
 $w_1$

$\uparrow$   
 $w_2$

# Ejemplo

- Reordenar de mayor a menor

- Valores propios (reordenados):

$$\lambda_1 = 1.284 \quad \lambda_2 = 0.049083$$

- Vectores propios (reordenados):

$$\begin{pmatrix} -0.67787 & -0.73518 \\ -0.73518 & 0.67787 \end{pmatrix}$$

$\uparrow$   
 $w_1$

$\uparrow$   
 $w_2$



# Ejemplo

- Transformación que descarta las covarianzas (mantiene el número de dimensiones):

$$W = (w_1; w_2) = \begin{pmatrix} -0.67787 & -0.73518 \\ -0.73518 & 0.67787 \end{pmatrix}$$



- Transformación que selecciona las k componentes principales:

$$W = (w_1) = \begin{pmatrix} -0.67787 \\ -0.73518 \end{pmatrix}$$

- Transformar los datos:

$$y = W^T \cdot \hat{x}$$



# Transformación



Transformación que mantiene el número de dimensiones, sólo elimina las covarianzas de los datos





# Reducción



Mantiene un  $\lambda_1/(\lambda_1+\lambda_2)=96.3\%$  del “total de la varianza” del conjunto

# Reconstrucción



Con la transformación inversa y sumando la promedio se pueden devolver los datos al espacio original



**USOS**

# Normalización de Pose

- PCA se puede usar para obtener ejes de rotación de un objeto
  - Permite normalizar la postura de un objeto
  - No funciona bien para objetos simétricos





# PCA sobre imágenes

- Usar la imagen gris como vector de  $W \times H$  dimensiones
- Usando PCA se reduce la dimensión, por ej., de varios miles a 256
- Se calcula distancia Euclidiana en el espacio de dimensión reducida

# Eigenfaces

- Sistema reconocedor de rostros.
- Cara promedio y los primeros 5 vectores propios





# PCA sobre imágenes

## ■ Eigenobjects:

- Si tenemos muchas imágenes parecidas, cada imagen puede ser vista como la imagen promedio más la suma ponderada de  $M$  vectores propios, llamados los “eigenobjects”
- Cada imagen de la colección se representa por un conjunto de  $M$  escalares



# Variantes de PCA

- PCA es un método lineal no supervisado
  - Transformaciones no lineales: Kernel PCA
  - Supervisado: Fisher's LDA
- Otros métodos: CCA, MDS, ICA, CFA, SOM, ISOMAP, LLE, NNCA.
- Específico a descriptores de texto: LSA



# Bibliografía

- **Multimedia Retrieval.** Blanken, de Vries, Blok, Feng. 2007.
  - pág 83 (PCA)
  - pág 165 (eigenobjects)

