Recuperación de Información Multimedia

Codebooks

CC5213 – Recuperación de Información Multimedia
Departamento de Ciencias de la Computación
Universidad de Chile
Juan Manuel Barrios – https://juan.cl/mir/ – 2020

Búsqueda de objetos

- ¿Cómo buscar las apariciones de ciertos objetos conocidos en uno o más videos?
  - Se tiene una o más imágenes de ejemplo para cada objeto buscado
  - Supuestos: Q imágenes de consulta, cada una con N_q descriptores locales. Video de M frames, cada frame con N_f descriptores locales
  - Q ~10, N_q ~1000, M ~10000 , N_f ~1000



Búsqueda de objetos

Descriptores Locales

- Opción 1:
  - De cada frame se obtienen sus descriptores y se comparan con los descriptores de la consulta
  - Se utiliza la coherencia espacial de los calces para decidir la ocurrencia del objeto
  - Buscar el objeto requiere $Q\ N_q\ N_f\ M$ distancias más $Q\ M$ cálculos de coherencia espacial

Búsquedas aproximadas

- Opción 2:
  - Calcular todos los descriptores locales en el video
  - Construir un índice con los descriptores de todo el video
  - Para cada descriptor de cada imagen de consulta realizar una búsqueda k-nn aproximada
  - Cada vecino más cercano encontrado suma un voto al frame que lo contiene
    - Ponderar el voto por el rank y distancia
  - Los frames con más votos deben contener el objeto
  - Construir un índice con N_f M vectores y realizar Q N_q búsquedas k-nn aproximadas

Búsquedas aproximadas

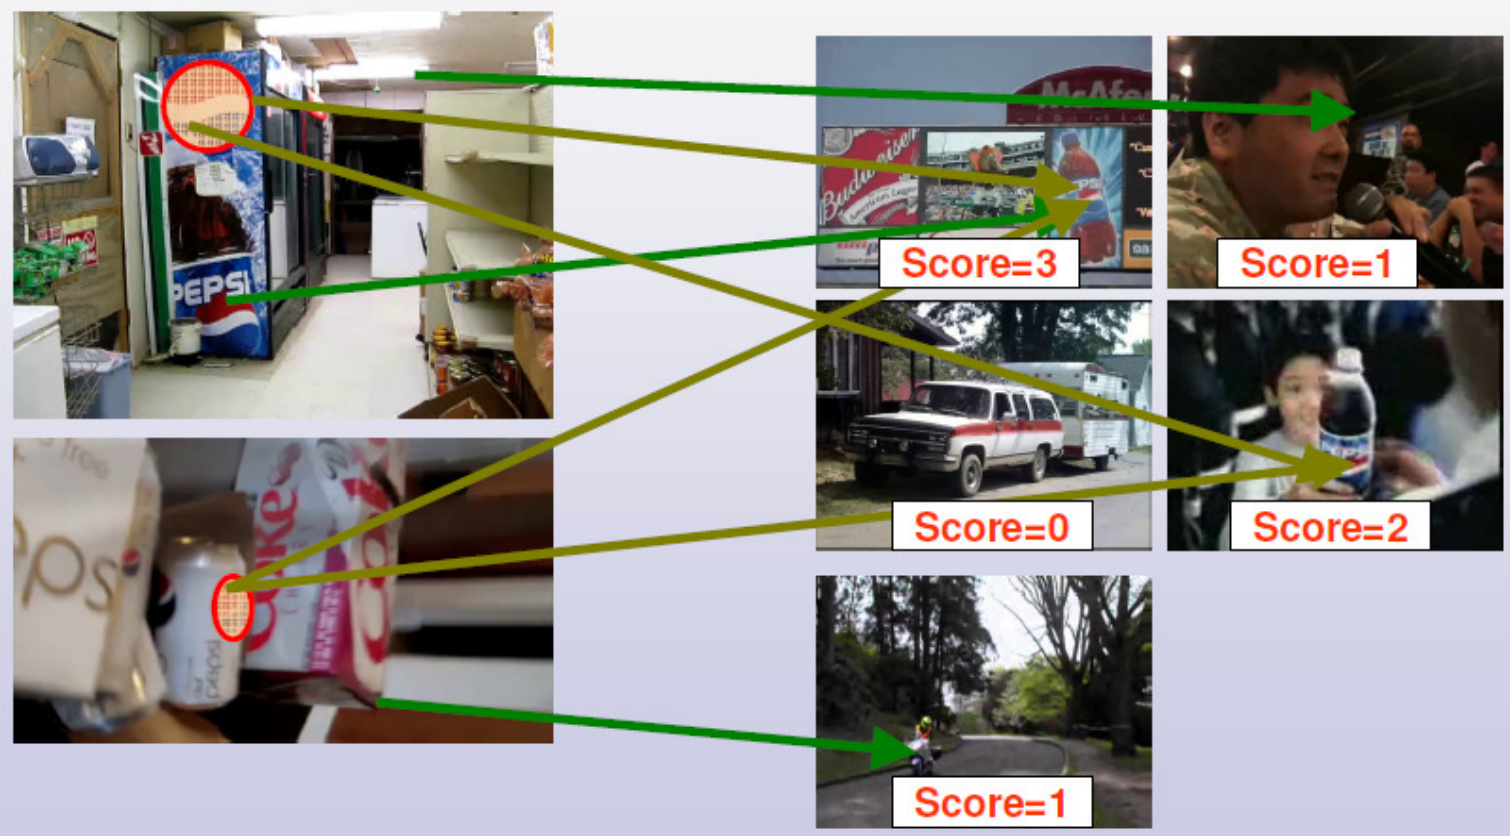

Palabras Visuales

- Opción 3:
  - Si un mismo objeto aparece en varios frames del video, lo más probable es que una gran cantidad de descriptores locales sean muy parecidos entre sí
  - Convertir el espacio continuo de descriptores a una cantidad discreta de descriptores (vocabulario visual)

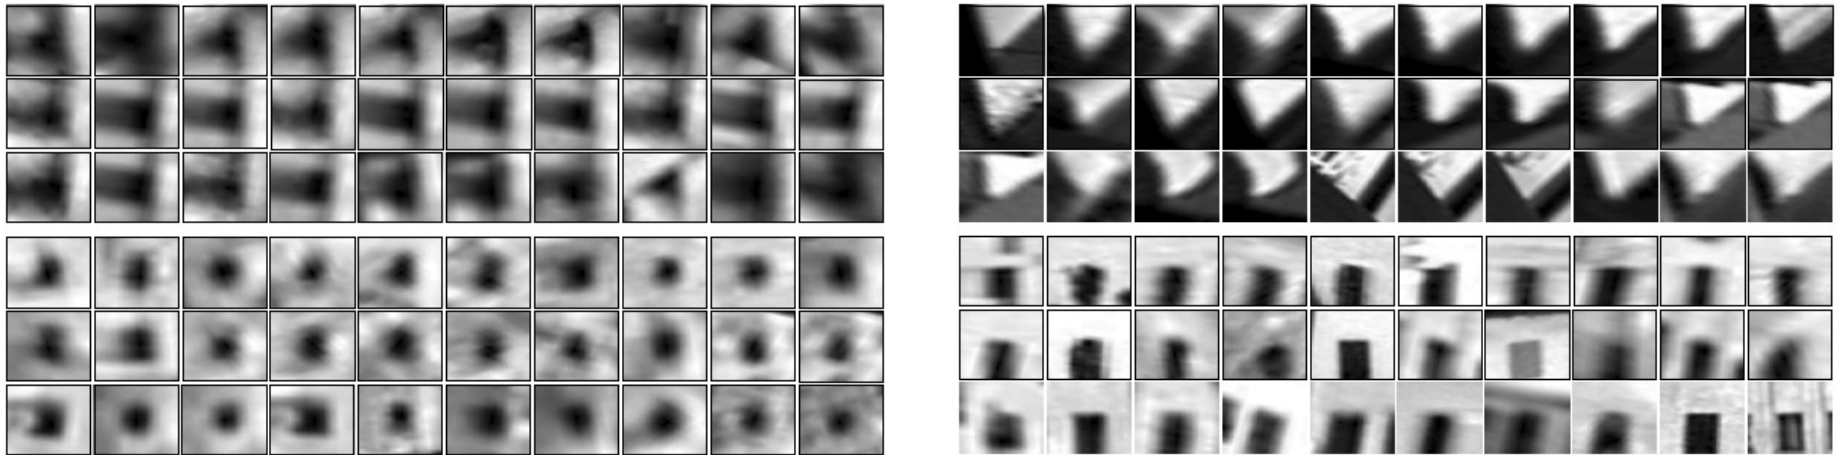

Sivic, Zisserman. “Video Google: A Text Retrieval Approach to Object Matching in Videos”, 2003.

Clustering

- Definir un conjunto finito de clusters (grupos, categorías o clases) de la colección de datos tales que:
  - Objetos en el *mismo* cluster deben ser lo más similares posible
  - Objetos en *diferentes* clusters deben ser lo más disímiles posible

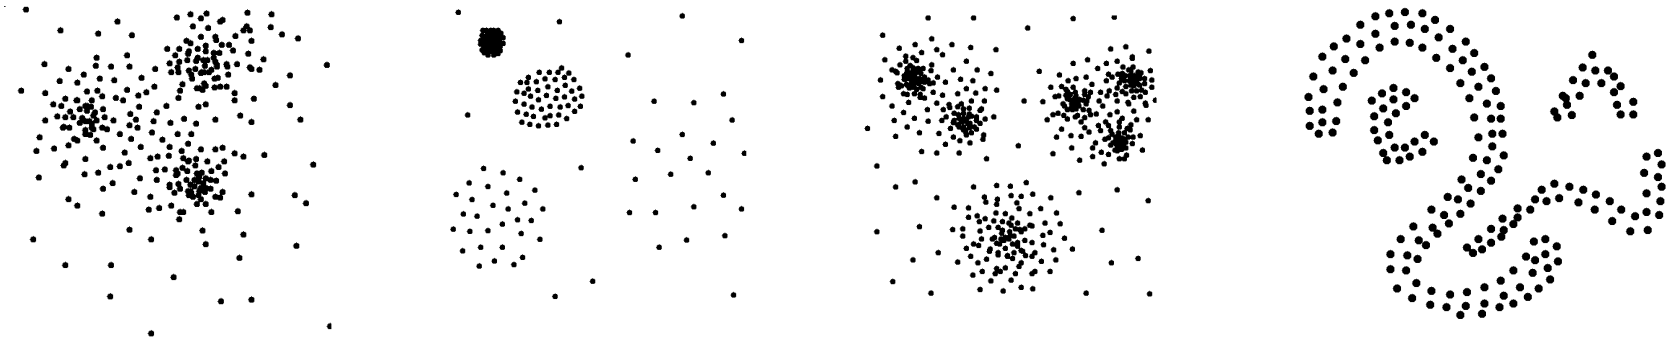

- **Propiedades de los cluster:**
  - clusters pueden tener tamaños, formas y densidades diferentes
  - clusters pueden formar una jerarquía
  - clusters pueden traslaparse o ser disjuntos

K-means

- Cada cluster se asocia con un centroide (punto central)
- Cada punto es asignado al cluster con el centroide más cercano
- El número de clusters K debe ser especificado

1: Select K points as the initial centroids.
2: **repeat**
3: Form K clusters by assigning all points to the closest centroid.
4: Recompute the centroid of each cluster.
5: **until** The centroids don't change

K-means Ejemplo 1

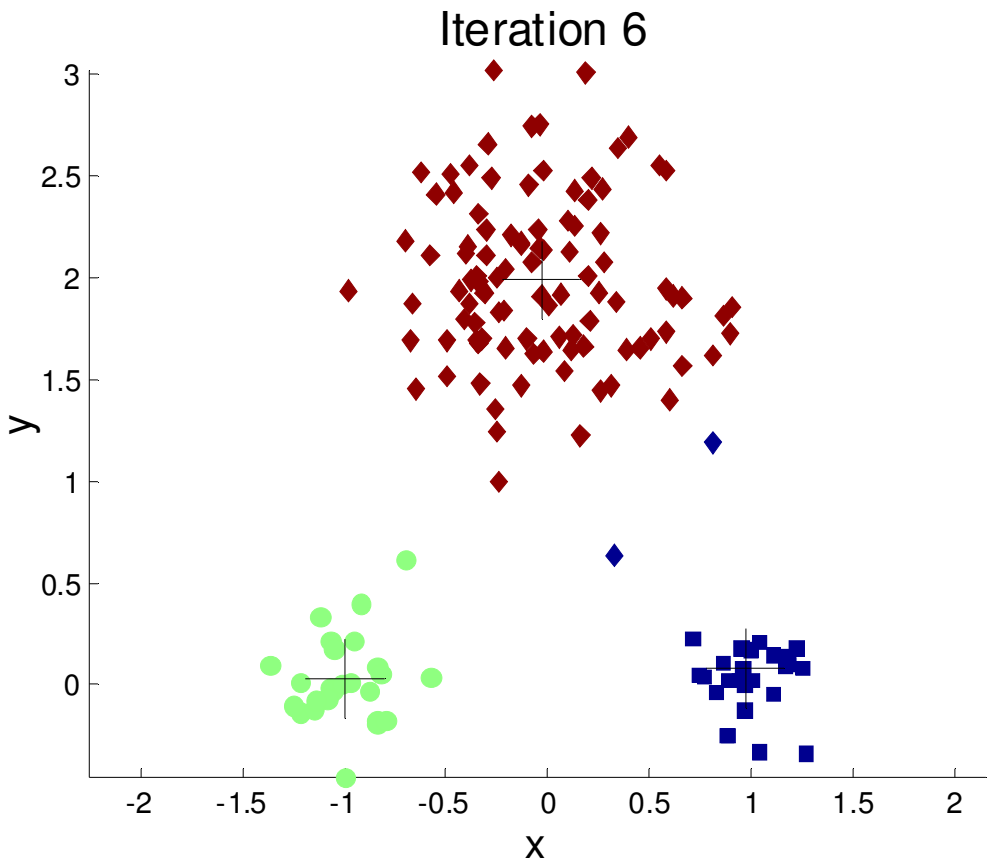

Fuente: http://www-users.cs.umn.edu/~kumar/dmbook/dmslides/chap8_basic_cluster_analysis.ppt

K-means Ejemplo 2

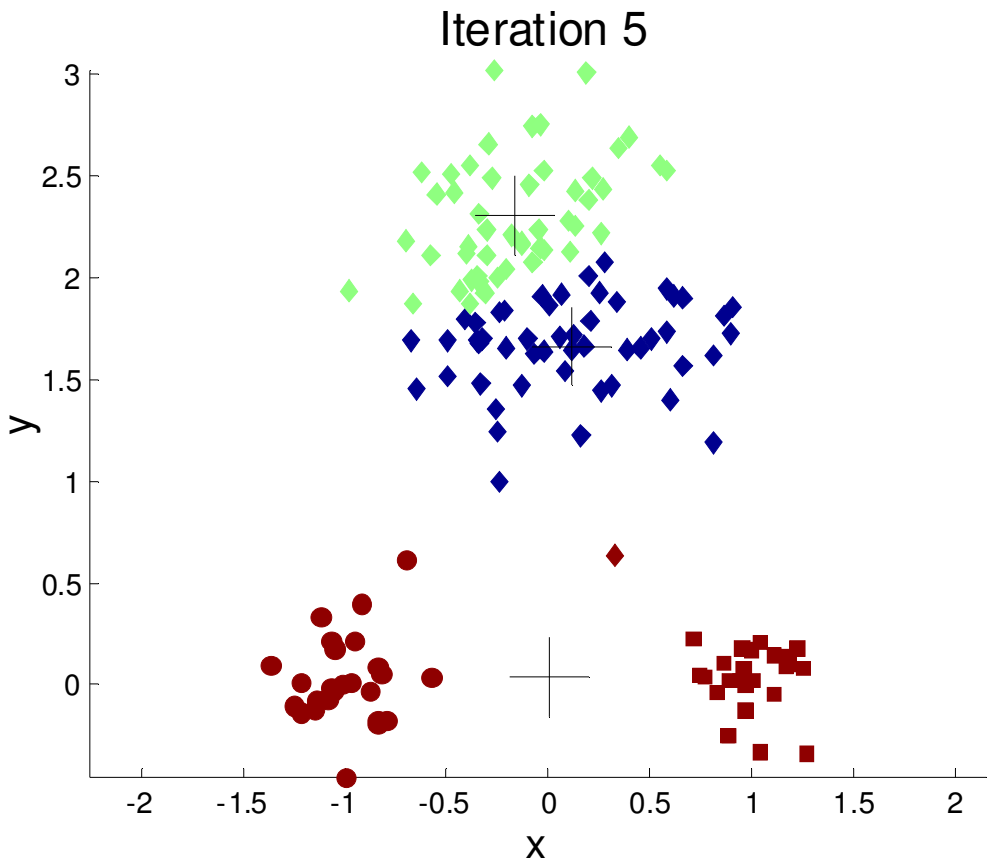

Fuente: http://www-users.cs.umn.edu/~kumar/dmbook/dmslides/chap8_basic_cluster_analysis.ppt

K-means

- Ventajas
  - Relativamente eficiente: O(**t k n**), donde: **n** es el número de vectores, **t** número de iteraciones (**t** << **n**), **k** es número de centroides
  - Fácil de implementar, paralelismo
- Desventajas
  - Muchas veces termina en un óptimo local
  - Utilizable sólo cuando el promedio está definido (no se puede utilizar en espacios métricos generales)
  - Enfocado en identificar clusters circulares
  - Necesita especificar **k** (número de clusters) como parámetro
  - No es robusto a ruido, outliers, densidades distintas

Cálculo de palabras visuales

- Dado un conjunto de descriptores locales calcular K clusters para formar un "**vocabulario visual**" o "**codebook**"
  - K-Means puede escalar a grandes cantidades de vectores.
- Cada centroide representa una "**palabra visual**"
- Se reemplaza cada descriptor local por la palabra visual más cercana.
- El tamaño del vocabulario incide en su representatividad (efectividad) y tiempo de clusterización y búsqueda (eficiencia)

Palabras visuales o Codebook

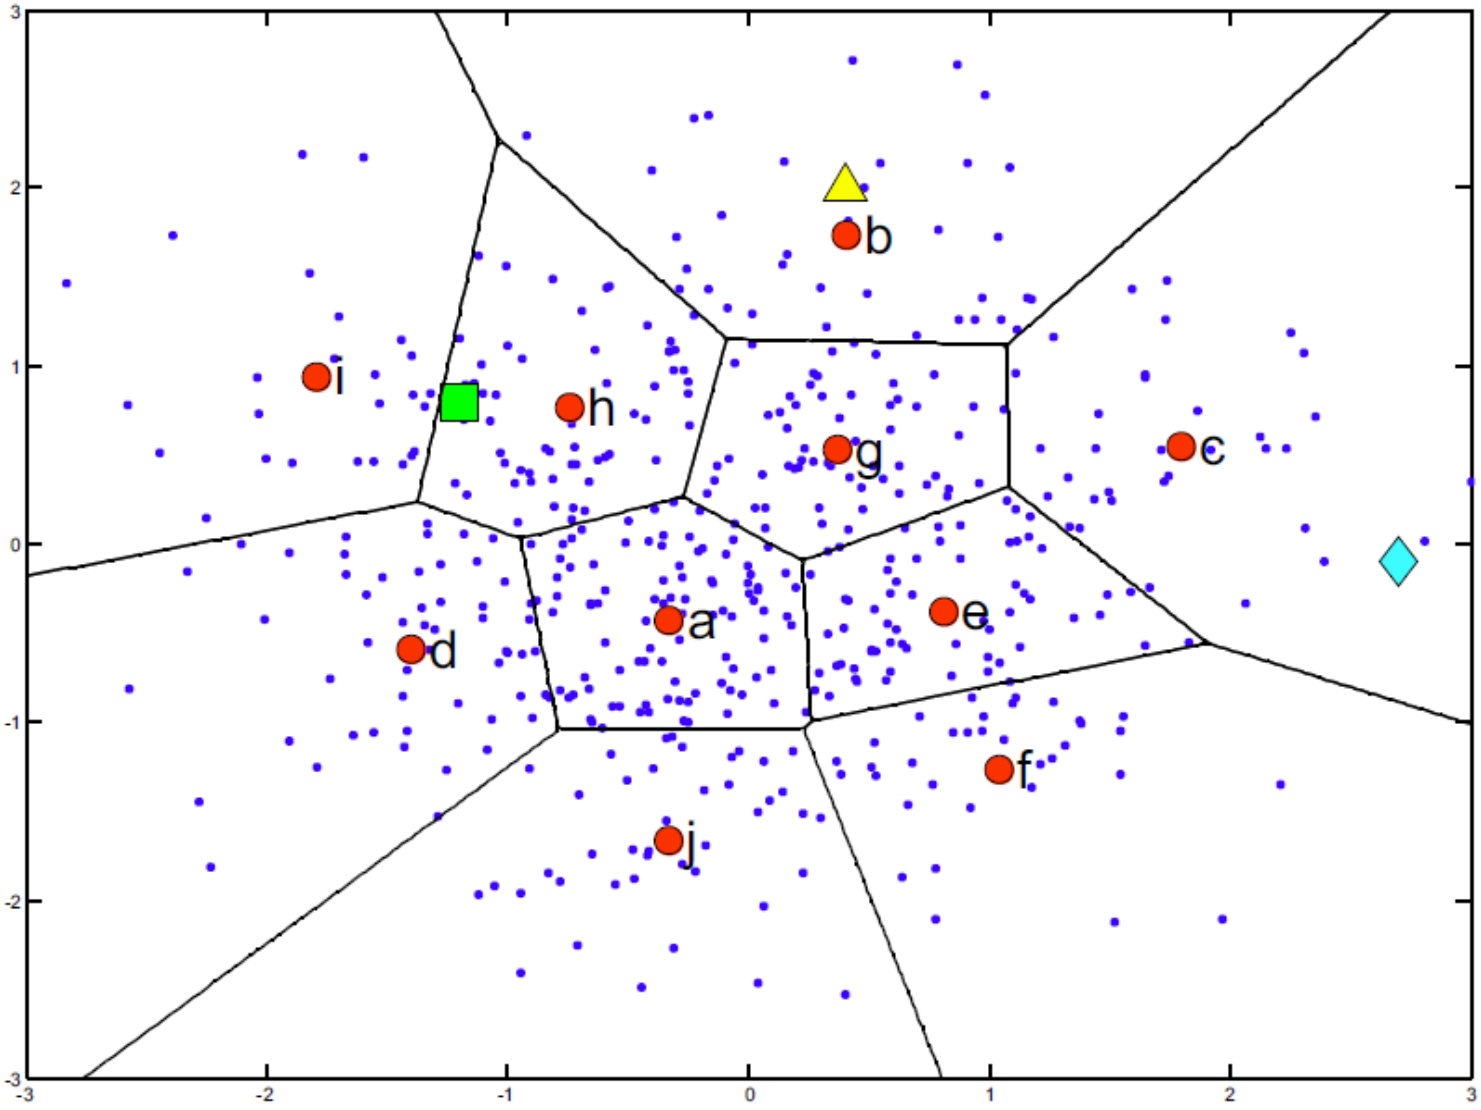

Bag-of-Visual-Words (BOVW)

- BOVW:
  - Descriptor global como agregación de descriptores locales
  - El descriptor de la imagen es un resumen de las “palabras visuales” que contiene
  - La búsqueda se basa en localizar los frames que comparten más “palabras visuales” con la consulta
  - Se puede usar un **índice invertido** para localizar frames con más coincidencias con la imagen de consulta

Bag-of-Visual-Words (BOVW)

- Comparación de imagen de consulta con frames usando similitud coseno
- Usar tf-idf para favorecer palabras visuales discriminativas y evitar palabras visuales ruidosas
  - *N*=número de imágenes en la colección
  - n_i=número de imágenes conteniendo la palabra *i*
  - $freq_{ij}$=cantidad de ocurrencias de la palabra *i* en la imagen *j*
  - n_d=número de palabras en la imagen *d*

$$(t_1, ..., t_i, ..., t_k)$$

$$w_{ij} = \begin{cases} (1 + \log(freq_{ij})) \times \log(\frac{N}{n_i}) & \text{si } freq_{ij} > 0 \\ 0 & \text{si no} \end{cases}$$

Coherencia Espacial

- Entre los frames candidatos (obtenidos por tf-idf) se deben preferir los que contienen palabras visuales en lugares parecidos a la consulta
- Opción 1: Realizar RANSAC entre frames y consulta
  - Los matches iniciales son las coincidencias de palabras visuales
  - Lento de ejecutar para muchos candidatos
- Opción 2: Usar ubiçación relativa entre palabra visuales precalculado en el Índice Invertido
  - En cada entrada del Índice Invertido junto con la palabra visual guardar palabras visuales cercanas espacialmente en el frame
  - En la imagen de consulta, para cada palabra visual determinar además las palabras visuales cercanas espacialmente
  - Al buscar favorecer las coincidencias que además tienen alta intersección entre sus listas de palabras visuales cercanas

Coincidencia de palabras visuales

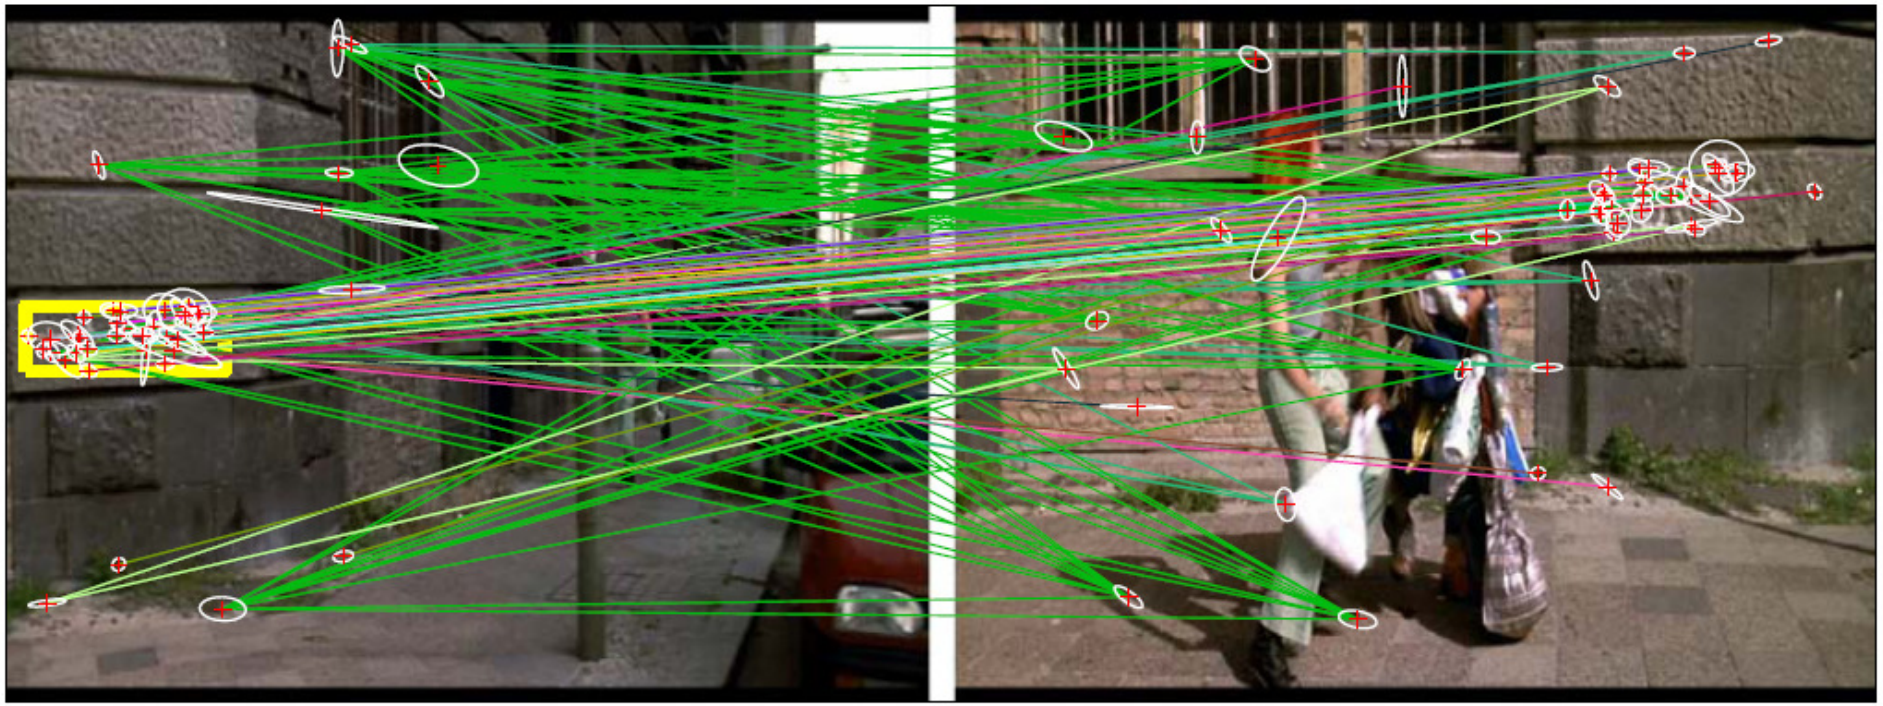

Sivic, Zisserman. “Video Google: A Text Retrieval Approach to Object Matching in Videos”, 2003.

Coherencia espacial de palabras visuales

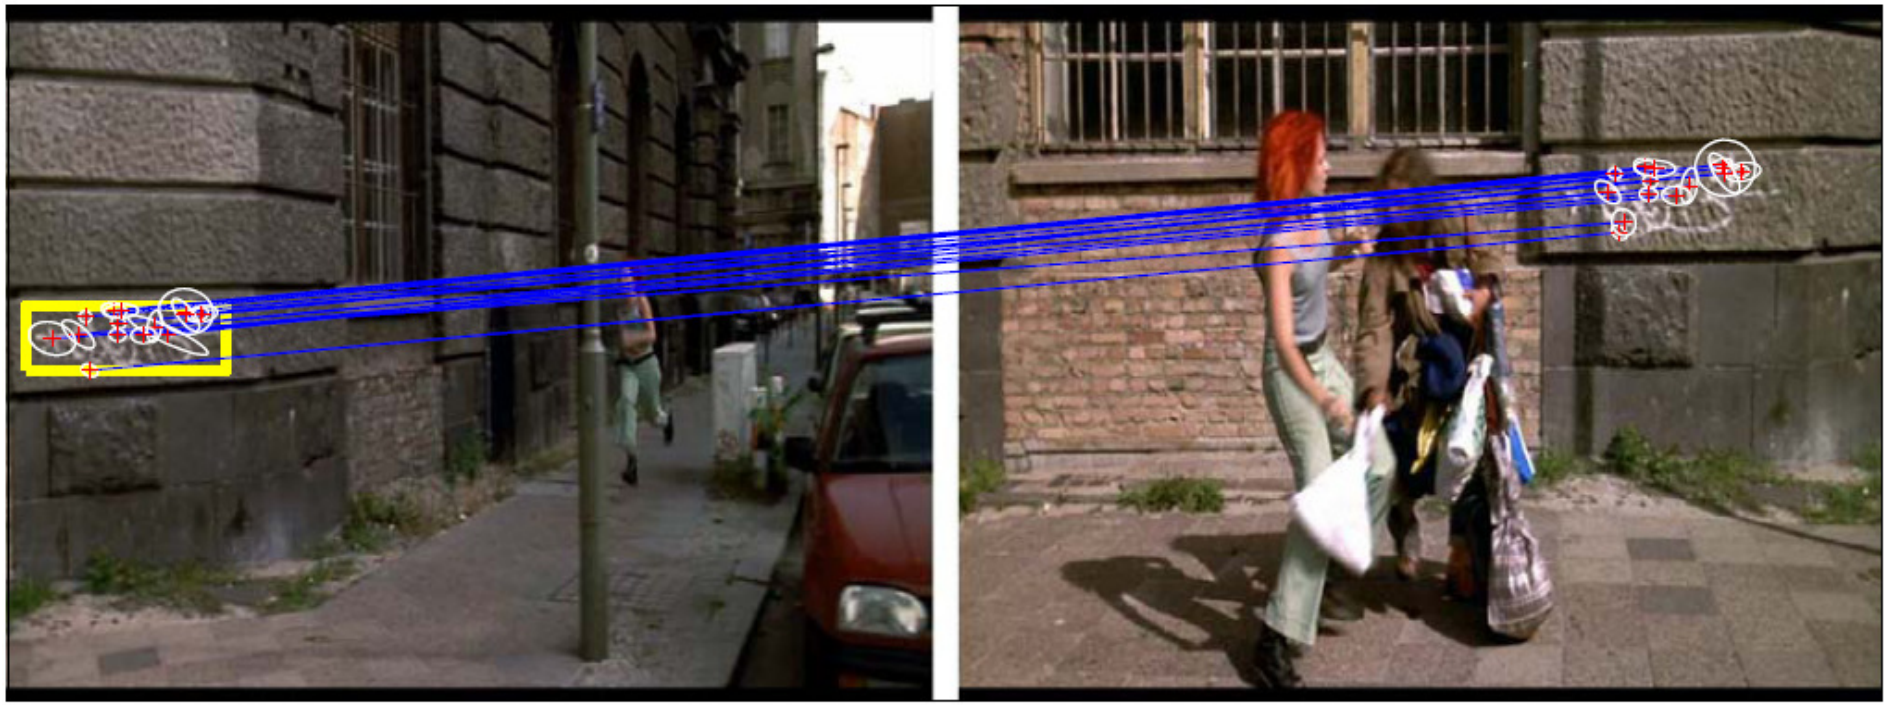

Sivic, Zisserman. “Video Google: A Text Retrieval Approach to Object Matching in Videos”, 2003.

Demo

http://www.robots.ox.ac.uk/~vgg/research/vgoogle/index.html

Clasificación de imágenes

- Dadas N clases (ej. aviones, gatos y bicicletas) con varias imágenes de entrenamiento, determinar la clase de una imagen de consulta
  - Ej: PASCAL VOC Challenge http://host.robots.ox.ac.uk/pascal/VOC/

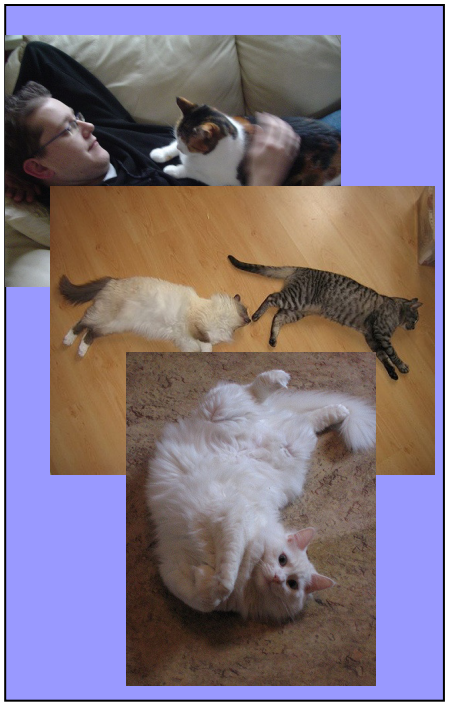

??

Clasificación de imágenes

- Imágenes de una misma clase (i.e., que muestran un mismo tipo de objeto) debieran compartir zonas con formas parecidas
  - Por ejemplo, ruedas en la clase bicicleta, alas en aviones, orejas en gatos, etc.
  - Al calcular descriptores locales, las imágenes de una misma clase debieran tener algunos descriptores locales parecidos
- Con las imágenes de entrenamiento calcular un vocabulario visual global
- Para cada imagen calcular un vector global que resume la aparición de las palabras visuales
- Un clasificador buscará el patrón de palabras visuales que identifica cada clase

Clasificación de imágenes con BOVW

- Calcular Codebook:
  - Definir imágenes de entrenamiento I
  - Calcular conjunto L de descriptores locales de I
  - Algoritmo de clustering sobre L o una selección de L
    - Usualmente k-Means por su eficiencia
    - Notar que incluso selección aleatoria de centros (i.e. k-Means con 1 iteración) puede ser usado con una pequeña baja en efectividad
- Calcular el descriptor BOVW de cada imagen:
  - Calcular descriptores locales de la imagen
  - Reemplazar cada descriptor local por el codeword más cercano
  - Calcular el vector de frecuencias de cada codeword en cada imagen
- Entrenar un clasificador con los descriptores BOVW

Coding Difuso

- **Hard Assignment**: Cada descriptor local se redondea al codeword más cercano
- **Soft Assignment**: Ponderar cada asignación según distribuciones por codeword.

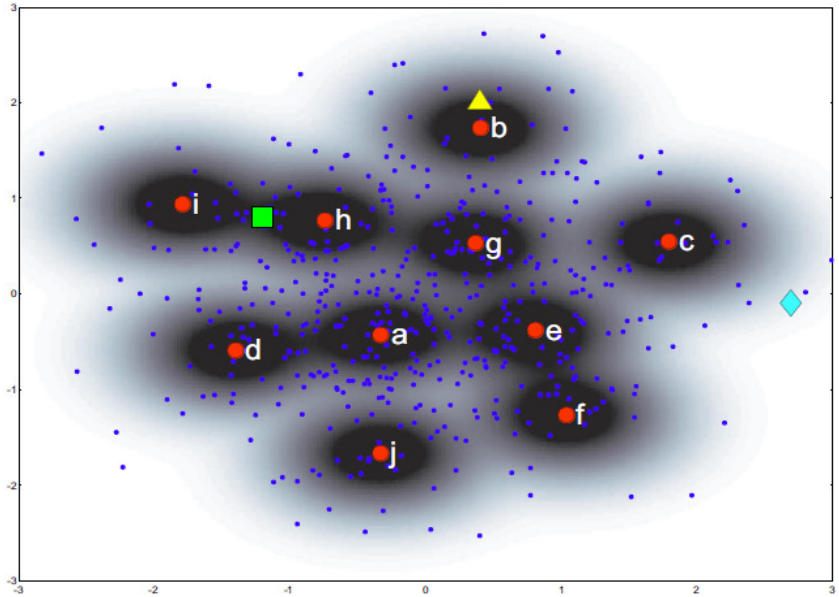

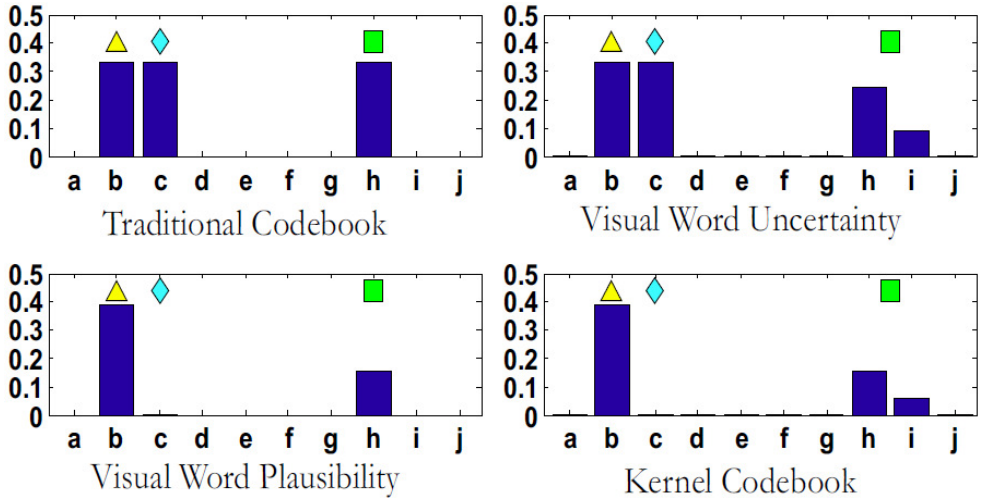

Van Gemert, Geusebroek. "Kernel Codebooks for Scene Categorization". 2008.

Coding/Pooling

- Generalización para calcular el descriptor global de una imagen con descriptores locales $\{x_1,..,x_N\}$ usando un codebook $\{c_1,..,c_M\}$
- **Coding**: Para cada descriptor local x_j calcular los pesos de cada codeword: $\alpha_{1j},\ldots,\alpha_{Mj}$
  - Asignación al más cercano, asignación difusa.
- **Pooling**: Para cada codeword c_m calcular su peso global según todos sus pesos: $\alpha_{m1},\ldots,\alpha_{mN}$
  - Average-pooling, Max-pooling

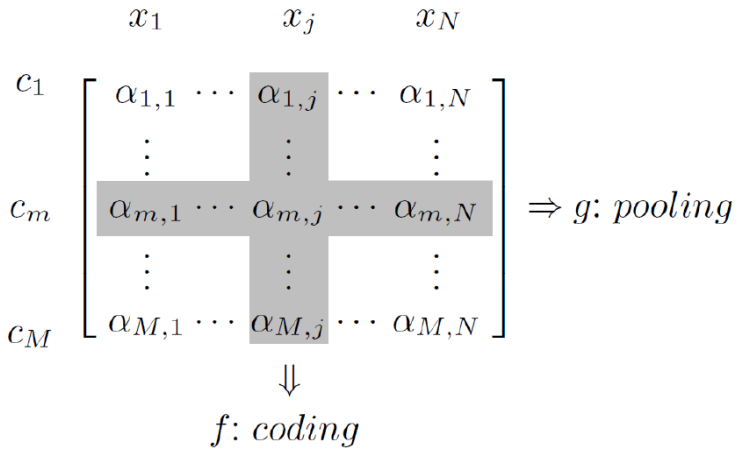

Ver Avila et al. 2011.

Variante: Bossa

- En la etapa de pooling, además del peso de cada c_i agregar un histograma de distancias normalizado de B bins (B entre 2 a 10)

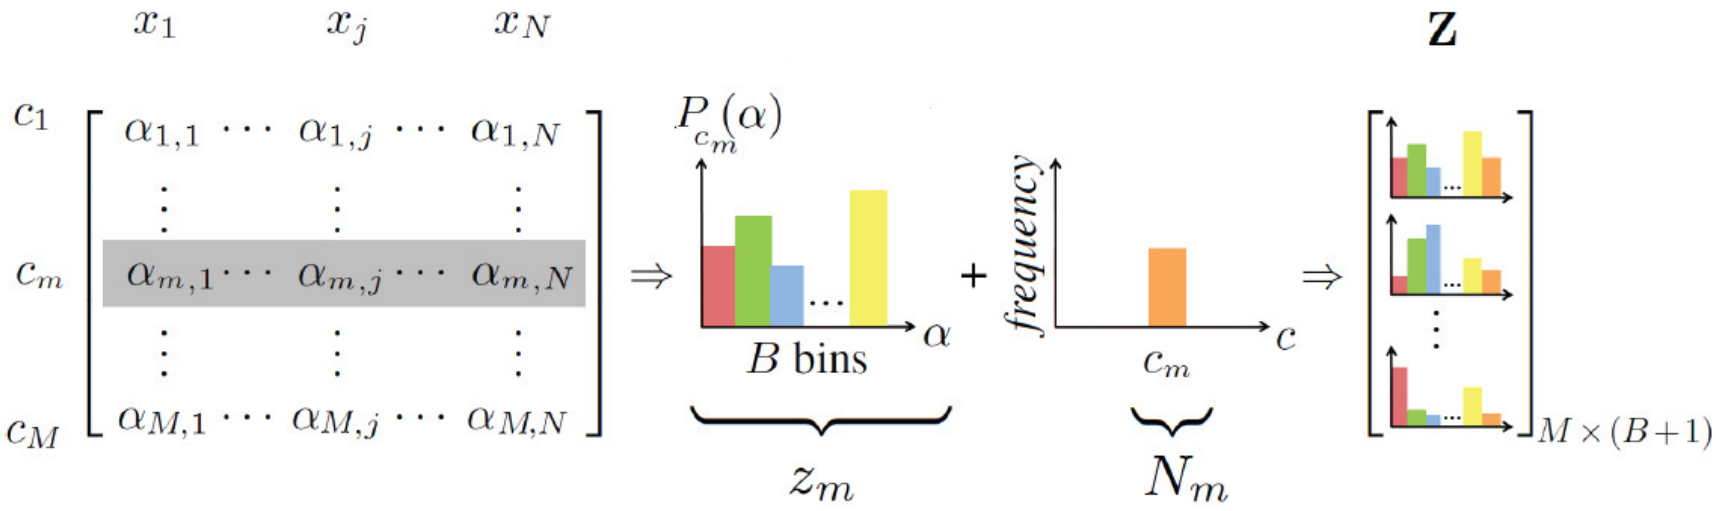

Ver Avila et al. 2011.

Variante: VLAD

- Previo:
  - PCA sobre todos los descriptores locales, usar *d* dimensiones
  - Calcular codebook de tamaño M
- Etapa de Coding:
  - Para cada descriptor local se busca el codeword más cercano c_i
  - Calcular el "vector residual" $(x-c_i)$ para c_i (0 para el resto)
  - Mejora 1: calcular vector de redondeo normalizado $(x-c_i)/||x-c_i||$
  - Mejora 2: utilizar matriz PCA independiente por c_i (pre-calculada)
- Etapa de Pooling
  - Para cada centro se suman sus vectores de redondeo
  - Se concatenan los vectores de error de los M codewords
- Descriptor de largo: M*d
- "power-law normalization" del descriptor VLAD
  - $x_i=|x_i|^a*\text{signo}(x_i)$ con $a < 1$ (Ej: raíz cuadrada)
- PCA sobre vectores VLAD

Ver Jegou et al. 2010.

Variante: Fisher Vectors

- Uso de GMM para describir la distribución de descriptores locales de entrenamiento:
  - Combinación lineal de K gaussianas, cada una con un peso, una media y una matriz de covarianza

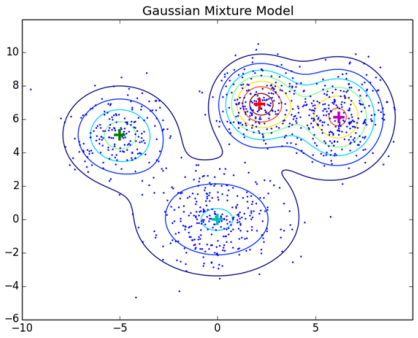

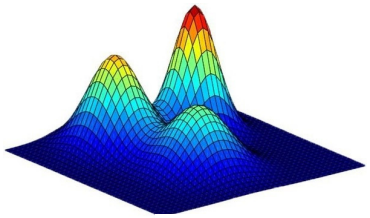

$$u_\lambda(x) = \sum_{k=1}^{K} w_k u_k(x)$$

$$u_k(x) = \frac{1}{(2\pi)^{D/2}|\Sigma_k|^{1/2}} \exp\left\{ -\frac{1}{2}(x-\mu_k)'\Sigma_k^{-1}(x-\mu_k) \right\}$$

$$\forall_k : w_k \geq 0, \qquad \sum_{k=1}^{K} w_k = 1$$

Ver Perronnin et al. 2010.

Fisher Vectors

- Coding: Para cada descriptor local se debe calcular para cada una de las K gaussianas:
  - Probabilidad de haber sido generado (escalar)
  - Desviación de la media (vector d-dim)
  - Desviación de la varianza (vector d-dim)
  - Cada descriptor local se codifica por 2d+1 valores por cada gaussiana
- Pooling:
  - Para cada gaussiana promediar las N codificaciones
  - Se concatenan los K codificaciones promedio
- Total: K(2d+1)
- Para acelerar cálculos usualmente se usan matrices Σ diagonales en la GMM

https://www.vlfeat.org/api/fisher-fundamentals.html

División Espacial

- Dense sampling:
  - No usar detector de keypoints
  - Los keypoints se obtienen a una tasa regular independiente de contenido de la imagen
  - Variar con un Δ contante la escala σ y ubicación (x,y)
- Spatial Pyramid:
  - Calcular un descriptor por cada zona 1x1, 2x2,1x3, etc.
  - Concatenar los descriptores de todas las zonas


Harris-Laplace salient points

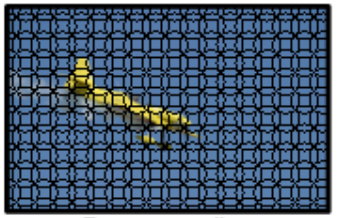
Dense sampling

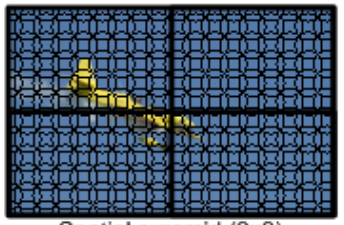
Spatial pyramid (2x2)

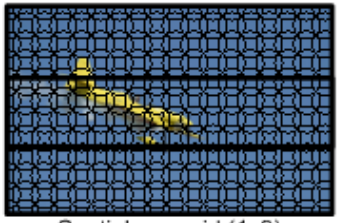
Spatial pyramid (1x3)

Combinación o Fusión

- Se desea crear un clasificador que combine N “modalidades” (e.g. color, audio, bordes, etc.).
- **Early fusion**: combinación en el espacio de descriptores.
  - Crear un solo descriptor como la concatenación de N descriptores.
  - Un único clasificador entrega una decisión combinada.
- **Late fusion**: combinación en el espacio semántico.
  - Se combina la decisión de N clasificadores.
  - Un clasificador por modalidad y luego se combinan los N scores (ya sea tomando el máximo, suma, etc.)

Clasificador de imágenes

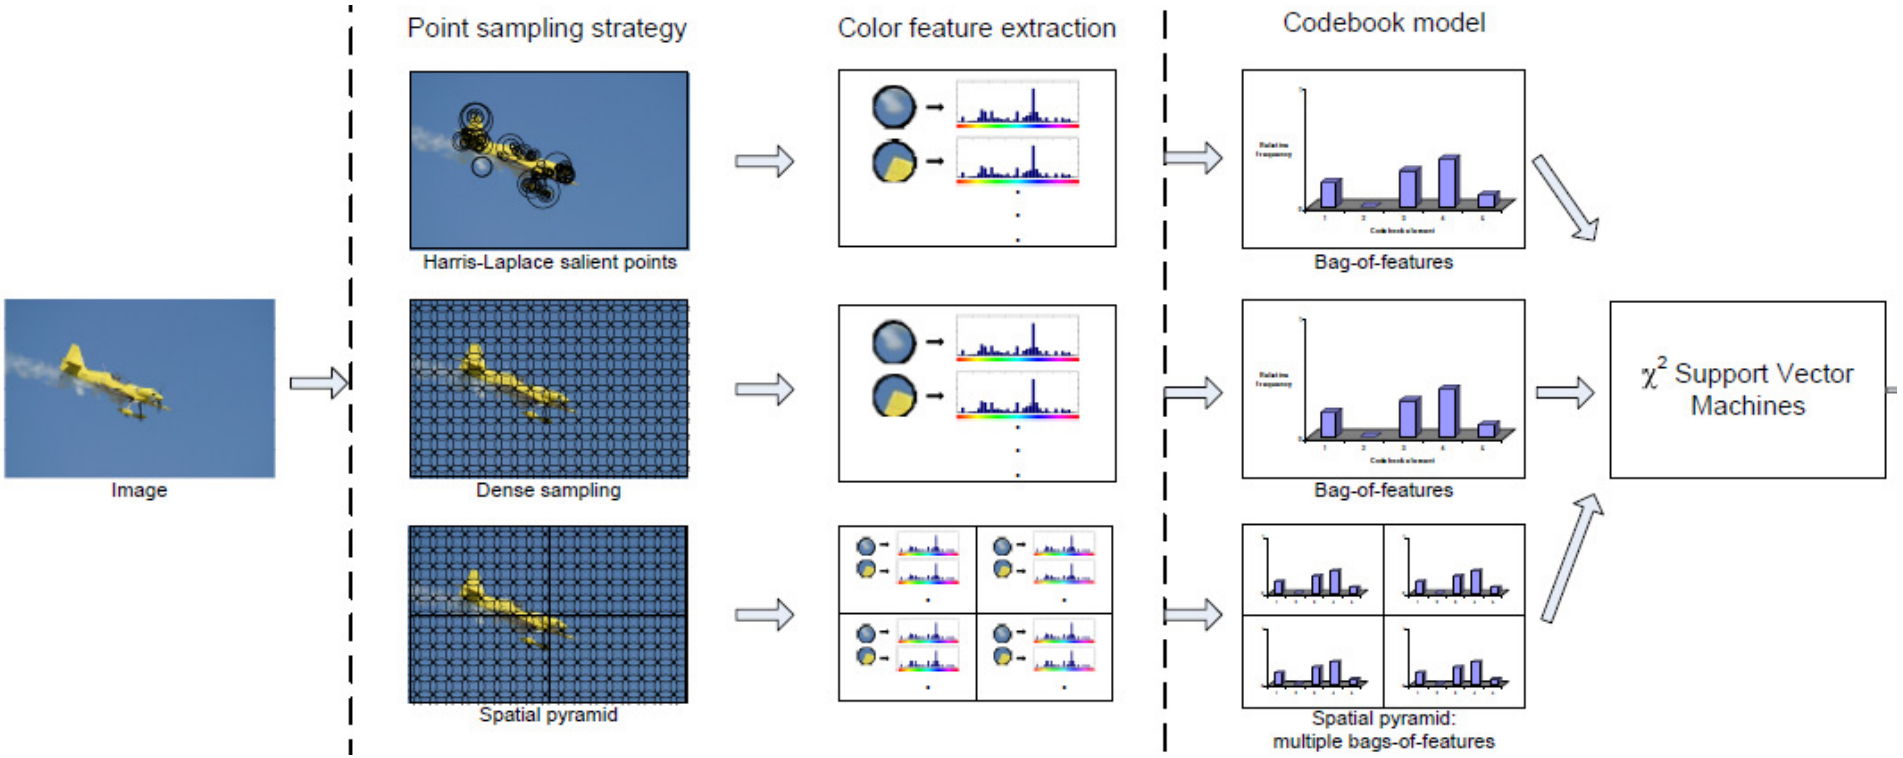

Ver: http://pascallin.ecs.soton.ac.uk/challenges/VOC/voc2008/workshop/tahir.pdf

Bibliografía

- Tan, Steinbach, Kumar. “Introduction to Data Mining”. 2005.
  - http://www-users.cs.umn.edu/~kumar/dmbook/index.php
  - Cap 4, Cap 8.
- Szeliski. Computer Vision: Algorithms and Applications.
  - Cap 14.3, 14.4.
- Duda, Hart, Stork. “Pattern Classification”, second edition. 2000.
  - Cap 1.
- Camastra, Vinciarelli. “Machine Learning for Audio, Image and Video Analysis: Theory and Applications”. 2007.

Papers

- Sivic, Zisserman. “Video Google: A Text Retrieval Approach to Object Matching in Videos”. ICCV, 2003.
- van Gemert, Geusebroek. “Kernel Codebooks for Scene Categorization”. 2008.
- Uijlings, Smeulders, Scha. “Real-time Bag of Words, Approximately”. CIVR, 2007.
- Snoek, Worring, Smeulders. “Early versus Late Fusion in Semantic Video Analysis”. 2005.
- Avila, Thome, Cord, Valle. “Bossa: Extended bow formalism for image classification”. 2011.
- Jegou, M. Douze, C. Schmid, and P. Perez. “Aggregating local descriptors into a compact image representation”. 2010.
- Delhumeau, Gosselin, Jégou, Pérez. “Revisiting the VLAD image representation”. 2013.
- Perronnin and Dance. “Fisher kenrels on visual vocabularies for image categorizaton”. 2006.
- Sanchez, Perronnin, Mensink, Verbeek. “Image Classification with the Fisher Vector: Theory and Practice”. 2013.